

Лабораторная работа по ML №4 Жуховицки

Датасет:

- [Student Performance](#)

Задачи:

- Выбрать датасет
- Загрузка и подготовка данных
- Провести базовый анализ: количество признаков, их типы (числовые/категориальные), наличие пропусков.
- Выбрать подмножество категориальных / дискретизируемых числовых признаков, отражающих принципиально важные для предсказания таргета знания (таргет также выбрать самостоятельно)
- Дискретизировать числовые признаки (если хотим использовать как входные данные, а также дискретизировать таргет, если он не является категорией)
- Определить целевую переменную
- Построение структуры Байесовской сети
- Определить логические зависимости между признаками (ориентированные рёбра).
- Составить структуру графа (DAG), отражающую причинно-следственные связи.
- Реализовать модель с помощью библиотеки PyAgrum или pgmpy:
- Визуализировать структуру сети.
- Обучение параметров сети
 - Обучить условные распределения (CPD) на данных с помощью метода максимального правдоподобия или байесовской оценки.
 - Проверить корректность полученных таблиц вероятностей (чтобы не было абсурдных значений)
- Инференс и анализ
 - Провести вероятностный вывод (inference): рассчитать вероятности целевой переменной при заданных наблюдениях.
 - Сравнить результаты при разных сценариях (взять например логически противоположные наблюдения).
- Выводы:
 - Сделать вывод о том, насколько Байесовская сеть адекватно описывает зависимости в данных.
 - Кратко сравнить Байесовскую сеть с классическими моделями (дерево решений, регрессия) по интерпретируемости и типу зависимостей.

Базовый анализ

Загрузим датасет

```
import pandas as pd
from ucimlrepo import fetch_ucirepo

student_performance = fetch_ucirepo(id=320)

X : pd.DataFrame = student_performance.data.features
y : pd.DataFrame = student_performance.data.targets

X
```

	school	sex	age	address	famsize	Pstatus	Medu	Fedu	Mjob	Fjob	...	higher	...
0	GP	F	18	U	GT3	A	4	4	at_home	teacher	...	yes	
1	GP	F	17	U	GT3	T	1	1	at_home	other	...	yes	
2	GP	F	15	U	LE3	T	1	1	at_home	other	...	yes	
3	GP	F	15	U	GT3	T	4	2	health	services	...	yes	
4	GP	F	16	U	GT3	T	3	3	other	other	...	yes	
...	...	...	...	...	...	...	...	...	...	...	...	...	...
644	MS	F	19	R	GT3	T	2	3	services	other	...	yes	
645	MS	F	18	U	LE3	T	3	1	teacher	services	...	yes	
646	MS	F	18	U	GT3	T	1	1	other	other	...	yes	
647	MS	M	17	U	LE3	T	3	1	services	services	...	yes	
648	MS	M	18	R	LE3	T	3	2	services	other	...	yes	

649 rows × 30 columns

Отключим лишние логи

```
import warnings
from tqdm import TqdmWarning

warnings.filterwarnings("ignore", category=TqdmWarning)
```

Выбираем как таргет финальную оценку студента, в датасете она называется G3, делаем единый датасет

```
df = X.join(y["G3"])

df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 649 entries, 0 to 648
Data columns (total 31 columns):
#   Column                Non-Null Count  Dtype
---  -
0   school                649 non-null   object
1   sex                   649 non-null   object
2   age                   649 non-null   int64
3   address               649 non-null   object
4   famsize               649 non-null   object
5   Pstatus               649 non-null   object
6   Medu                  649 non-null   int64
7   Fedu                  649 non-null   int64
8   Mjob                  649 non-null   object
9   Fjob                  649 non-null   object
10  reason                649 non-null   object
11  guardian              649 non-null   object
12  traveltime            649 non-null   int64
13  studytime             649 non-null   int64
14  failures              649 non-null   int64
15  schoolsup             649 non-null   object
16  famsup                649 non-null   object
17  paid                  649 non-null   object
18  activities            649 non-null   object
19  nursery               649 non-null   object
20  higher                649 non-null   object
21  internet              649 non-null   object
22  romantic              649 non-null   object
23  famrel                649 non-null   int64
24  freetime              649 non-null   int64
25  goout                 649 non-null   int64
26  Dalc                  649 non-null   int64
27  Walc                  649 non-null   int64
28  health                649 non-null   int64
29  absences              649 non-null   int64
30  G3                    649 non-null   int64
dtypes: int64(14), object(17)
memory usage: 157.3+ KB
```

Пропусков нет. В датасете есть категориальные и уже дискретизированные числовые признаки, посмотрим насколько обширно количество вариантов этих категорий

```
for i in df.columns:
    print(df[i].nunique(), end=", ")
```

2, 2, 8, 2, 2, 2, 5, 5, 5, 5, 4, 3, 4, 4, 4, 2, 2, 2, 2, 2, 2, 2, 5, 5, 5, 5, 5, 5, 24, 17,

Вариантов категорий довольно мало, было бы очень удобно использовать label encoding, сделаем же это! Приведём категориальные признаки к числовым дискретизированным.

```
from sklearn.preprocessing import LabelEncoder

le = LabelEncoder()
```

```
for col in df.columns:
    if df[col].dtype == 'object':
        df[col] = le.fit_transform(df[col])
```

df

	school	sex	age	address	famsize	Pstatus	Medu	Fedu	Mjob	Fjob	...	internet	roman
0	0	0	18	1	0	0	4	4	0	4	...	0	
1	0	0	17	1	0	1	1	1	0	2	...	1	
2	0	0	15	1	1	1	1	1	0	2	...	1	
3	0	0	15	1	0	1	4	2	1	3	...	1	
4	0	0	16	1	0	1	3	3	2	2	...	0	
...	...	...	...	...	...	...	...	...	...	...	...	...	...
644	1	0	19	0	0	1	2	3	3	2	...	1	
645	1	0	18	1	1	1	3	1	4	3	...	1	
646	1	0	18	1	0	1	1	1	2	2	...	0	
647	1	1	17	1	1	1	3	1	3	3	...	1	
648	1	1	18	0	1	1	3	2	3	2	...	1	

649 rows × 31 columns

Теперь можно посмотреть и корреляцию признаков между собой!

```
import seaborn as sns
import matplotlib.pyplot as plt

matrix = df.corr()

plt.figure(figsize=(25,17))
sns.heatmap(matrix, annot=True, fmt=".3f")
plt.show()
```

	school	sex	age	address	famsize	Pstatus	Medu	Fedu	Mjob	Fjob	reason	guardian	traveltime	studytime	failures	schoolsup	famsup	paid	activities	nursery	higher	internet	romantic
school	1.000	-0.083	0.087	-0.355	0.022	0.028	-0.255	-0.210	-0.207	-0.082	-0.110	-0.062	0.253	-0.138	0.114	-0.123	-0.064	-0.008	-0.089	0.005	-0.136	-0.240	0.072
sex	-0.083	1.000	-0.044	0.026	0.098	0.065	0.119	0.084	0.150	0.080	0.011	-0.037	-0.037	-0.206	0.074	-0.111	-0.129	0.079	0.125	-0.044	-0.058	0.066	-0.110
age	0.087	-0.044	1.000	-0.026	-0.002	-0.006	-0.108	-0.121	-0.072	-0.051	-0.026	0.267	0.034	-0.008	0.320	-0.168	-0.102	-0.005	-0.054	-0.021	-0.265	0.013	0.179
address	-0.355	0.026	-0.026	1.000	0.046	-0.095	0.190	0.141	0.160	-0.007	-0.002	-0.019	-0.345	0.062	-0.064	0.018	0.006	-0.030	-0.009	0.018	0.077	0.176	-0.031
famsize	0.022	0.098	-0.002	0.046	1.000	-0.240	-0.014	-0.040	0.020	-0.059	0.032	0.001	0.013	-0.011	-0.066	-0.056	-0.040	-0.050	-0.015	0.101	0.005	0.013	-0.033
Pstatus	0.028	0.065	-0.006	-0.095	-0.240	1.000	-0.057	-0.032	-0.029	0.054	-0.031	-0.170	0.041	-0.009	-0.010	-0.009	0.010	0.016	0.102	-0.033	0.023	0.060	-0.054
Medu	-0.255	0.119	-0.108	0.190	-0.014	-0.057	1.000	0.647	0.459	0.153	0.133	-0.014	-0.265	0.097	-0.172	-0.022	0.120	0.114	0.119	0.126	0.214	0.266	-0.031
Fedu	-0.210	0.084	-0.121	0.141	-0.040	-0.032	0.647	1.000	0.291	0.212	0.081	-0.102	-0.208	0.050	-0.166	0.024	0.135	0.095	0.080	0.075	0.192	0.183	0.183
Mjob	-0.207	0.150	-0.072	0.160	0.020	-0.029	0.459	0.291	1.000	0.203	0.059	0.008	-0.164	0.057	-0.118	0.008	0.039	0.012	0.100	0.042	0.148	0.261	-0.068
Fjob	-0.082	0.080	-0.051	-0.007	-0.059	0.054	0.153	0.212	0.203	1.000	0.043	-0.075	0.005	-0.019	-0.055	-0.013	-0.039	-0.021	0.018	-0.046	0.090	0.089	-0.003
reason	-0.110	0.011	-0.026	-0.002	0.032	-0.031	0.133	0.081	0.059	0.043	1.000	-0.066	-0.093	0.136	-0.144	0.048	0.011	-0.051	0.077	0.044	0.091	0.110	-0.051
guardian	-0.062	-0.037	0.267	-0.019	0.001	-0.170	-0.014	-0.102	0.008	-0.075	-0.066	1.000	0.027	-0.010	0.170	-0.041	0.016	0.072	0.014	-0.023	-0.115	-0.000	0.106
traveltime	0.253	0.041	0.034	-0.345	0.013	0.041	-0.265	-0.208	-0.164	0.005	-0.093	0.027	1.000	-0.093	0.027	0.027	0.016	0.072	0.014	-0.023	-0.115	-0.000	0.106
studytime	-0.138	-0.206	-0.008	0.062	-0.011	-0.009	0.097	0.050	0.057	-0.019	0.136	-0.010	-0.093	1.000	-0.093	-0.093	0.016	0.072	0.014	-0.023	-0.115	-0.000	0.106
failures	0.114	0.074	0.320	-0.064	-0.066	-0.010	-0.172	-0.166	-0.118	-0.055	-0.144	0.170	0.027	-0.093	1.000	-0.093	0.016	0.072	0.014	-0.023	-0.115	-0.000	0.106
schoolsup	-0.123	-0.111	-0.168	0.018	-0.056	-0.009	-0.022	0.024	0.008	-0.013	0.048	-0.041	-0.093	-0.093	-0.093	1.000	0.016	0.072	0.014	-0.023	-0.115	-0.000	0.106
famsup	-0.064	-0.129	-0.102	0.006	-0.040	0.010	0.120	0.135	0.039	-0.039	0.011	0.016	0.027	-0.093	0.016	0.016	1.000	0.072	0.014	-0.023	-0.115	-0.000	0.106
paid	-0.008	0.079	-0.005	-0.030	-0.050	0.016	0.114	0.095	0.012	-0.021	-0.051	0.072	0.027	-0.093	0.072	0.072	0.072	1.000	0.014	-0.023	-0.115	-0.000	0.106
activities	-0.089	0.125	-0.054	-0.009	-0.015	0.102	0.119	0.080	0.100	0.018	0.077	0.014	-0.093	-0.093	0.014	0.014	0.014	0.014	1.000	-0.023	-0.115	-0.000	0.106
nursery	0.005	-0.044	-0.021	0.018	0.101	-0.033	0.126	0.075	0.042	-0.046	0.044	-0.023	-0.093	-0.093	-0.023	-0.023	-0.023	-0.023	-0.023	1.000	-0.115	-0.000	0.106
higher	-0.136	-0.058	-0.265	0.077	0.005	0.023	0.214	0.192	0.148	0.090	0.091	-0.115	-0.093	-0.093	-0.115	-0.115	-0.115	-0.115	-0.115	-0.115	1.000	-0.000	0.106
internet	-0.240	0.066	0.013	0.176	0.013	0.060	0.266	0.183	0.261	0.089	0.110	-0.000	-0.093	-0.093	-0.000	-0.000	-0.000	-0.000	-0.000	-0.000	-0.000	1.000	0.106
romantic	0.072	-0.110	0.179	-0.031	-0.033	-0.054	-0.031	-0.068	-0.074	-0.003	-0.051	0.106	0.027	-0.093	0.106	0.106	0.106	0.106	0.106	0.106	0.106	0.106	1.000



Сразу отбросим признаки с низкой корреляцией по порогу 0.2

```
churn_corr = df.corr().abs()["G3"]
feature_names = df.columns.drop("G3")
cols_to_drop = churn_corr[feature_names][churn_corr[feature_names] < 0.2]

df.drop(cols_to_drop.index, inplace=True, axis=1)

plt.figure(figsize=(13, 9))
sns.heatmap(df.corr(), annot=True, fmt=".3f")
plt.show()
```



Начало основной обработки и создание сети

Вот теперь можно разобрать значение каждого из столбцов, с которыми будем работать.

Столбцы:

- school - столбец, который определяет 1 из 2 учебных заведений, где мог быть студент
- Medu - уровень образования матери
- Fedu - уровень образования отца
- studytime - время, которое студент тратит на обучение

- failures - количество неудач, которые потерпел студент в прошлых классах
- higher - желает ли студент получить высшее образование
- Dalc - потребление алкоголя в рабочее время

Если подумать, то можно выстроить некоторые цепочки из признаков, которые действительно логически соотносятся. Создадим сеть и добавим туда признаки.

```
from pyagrum import BayesNet, IntegerVariable, RangeVariable

network = BayesNet()
[network.add(IntegerVariable(name, name, df[name].unique().tolist())) for name in df.columns]
network.add(RangeVariable("G3", "G3", 0, 19))
```


network



Основываясь на своём жизненном опыте, я составил кажущуюся мне логичной сеть из признаков. Например, от образования родителей зависит, в какое учебное заведение попадёт ребёнок и будет ли он стремиться к высшему образованию.

```
network.addArc("Fedu", "school")
network.addArc("Medu", "school")
network.addArc("Fedu", "higher")
network.addArc("Medu", "higher")
network.addArc("school", "failures")
network.addArc("higher", "G3")
network.addArc("failures", "G3")
network.addArc("Dalc", "G3")
network.addArc("studytime", "G3")
```

network



Отлично, конфигурация сети готова! Обучим же её на наших данных и провалидируем результат, рассмотрим распределение вероятностей. Используем байесовскую оценку.

```
from pyagrum import BN Learner

learner = BN Learner(df, network)
learner.useSmoothingPrior()
bn = learner.learnParameters(network)

for item in bn.names():
    print(f"{item}: {bn.cpt(item)}")
```

higher:

		higher	
Fedu	Medu	0	1
0	0	0.3333	0.6667
1	0	0.5000	0.5000
2	0	0.2000	0.8000
3	0	0.5000	0.5000
4	0	0.5000	0.5000
0	1	0.1429	0.8571
[...13 more line(s) ...]			
4	3	0.0400	0.9600
0	4	0.3333	0.6667
1	4	0.1000	0.9000
2	4	0.0345	0.9655
3	4	0.0217	0.9783
4	4	0.0309	0.9691

Medu:

Medu	
0	1
0.0107	0.2202

studytime:

studytime	
1	2
0.3262	0.4686

Dalc:

Dalc	
1	2
0.6911	0.1865

failures:

		failures	
school	0	1	2
0	0.8829	0.0703	0.0258
1	0.7565	0.1826	0.0304

Fedu:

Fedu	
0	1
0.0122	0.2676

school:

		school	
Fedu	Medu	0	1
0	0	0.3333	0.6667
1	0	0.5000	0.5000
2	0	0.6000	0.4000

```

3      |0      || 0.5000 | 0.5000 |
4      |0      || 0.5000 | 0.5000 |
0      |1      || 0.4286 | 0.5714 |
[...13 more line(s) ...]
4      |3      || 0.8400 | 0.1600 |
0      |4      || 0.6667 | 0.3333 |
1      |4      || 0.3000 | 0.7000 |
2      |4      || 0.7586 | 0.2414 |
3      |4      || 0.8913 | 0.1087 |
4      |4      || 0.7423 | 0.2577 |

```

G3:

```

|| G3
|
higher|failur|Dalc  |studyt||0      |1      |2      |3      |4      |5
|6      |7      |8      |9      |10     |11     |12     |13     |14
|15     |16     |17     |18     |19     |
-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
---|-----|-----|-----|-----|-----|-----|-----|-----|-----|
-----|-----|-----|-----|-----|-----|
0      |0      |1      |1      || 0.0312 | 0.0312 | 0.0312 | 0.0312 | 0.0312 | 0.031
2      | 0.0312 | 0.0625 | 0.0625 | 0.0938 | 0.1250 | 0.1562 | 0.0312 | 0.0625 |
0.0312 | 0.0312 | 0.0312 | 0.0312 | 0.0312 | 0.0312 | 0.0312 |
1      |0      |1      |1      || 0.0190 | 0.0095 | 0.0095 | 0.0095 | 0.0095 | 0.009
5      | 0.0190 | 0.0190 | 0.0286 | 0.0476 | 0.0857 | 0.1333 | 0.1714 | 0.1333 |
0.0952 | 0.0762 | 0.0476 | 0.0476 | 0.0190 | 0.0095 |
0      |1      |1      |1      || 0.0769 | 0.0385 | 0.0385 | 0.0385 | 0.0385 | 0.038
5      | 0.0385 | 0.0769 | 0.0769 | 0.0385 | 0.1538 | 0.0385 | 0.0385 | 0.0385 |
0.0385 | 0.0385 | 0.0385 | 0.0385 | 0.0385 | 0.0385 |
1      |1      |1      |1      || 0.0606 | 0.0303 | 0.0303 | 0.0303 | 0.0303 | 0.030
3      | 0.0303 | 0.0303 | 0.0909 | 0.1212 | 0.1515 | 0.0606 | 0.0303 | 0.0909 |
0.0303 | 0.0303 | 0.0303 | 0.0303 | 0.0303 | 0.0303 |
0      |2      |1      |1      || 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.050
0      | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
1      |2      |1      |1      || 0.0476 | 0.0476 | 0.0476 | 0.0476 | 0.0476 | 0.047
6      | 0.0476 | 0.0476 | 0.0476 | 0.0476 | 0.0476 | 0.0476 | 0.0476 | 0.0476 |
0.0476 | 0.0952 | 0.0476 | 0.0476 | 0.0476 | 0.0476 |
[...148 more line(s) ...]
0      |1      |5      |4      || 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.050
0      | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
1      |1      |5      |4      || 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.050
0      | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
0      |2      |5      |4      || 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.050
0      | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
1      |2      |5      |4      || 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.050
0      | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
0      |3      |5      |4      || 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.050
0      | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |
1      |3      |5      |4      || 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.050
0      | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |

```

0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 | 0.0500 |

Подготовим инференс, чтобы попробовать рассмотреть какие-либо вероятности и проверять модель.

```
from pyagrum import LazyPropagation
```

```
ie = LazyPropagation(bn)  
ie.makeInference()
```

```
print(ie.posterior("G3"))
```


```
G3  
|  
0      |1      |2      |3      |4      |5      |6      |7      |8  
|9      |10     |11     |12     |13     |14     |15     |16     |17  
|18     |19     |       |12     |13     |14     |15     |16     |17  
-----|-----|-----|-----|-----|-----|-----|-----|-----|  
----|-----|-----|-----|-----|-----|-----|-----|-----|  
-----|-----|-----|  
0.0292 | 0.0216 | 0.0215 | 0.0215 | 0.0215 | 0.0215 | 0.0231 | 0.0257 | 0.04  
30 | 0.0456 | 0.0934 | 0.1118 | 0.0945 | 0.1049 | 0.0841 | 0.0715 | 0.0572 |  
0.0497 | 0.0354 | 0.0232 |
```

Валидация результата и тесты

Посмотрим что получилось! Рассмотрим инференс для всей сети

```
from pyagrum.lib.notebook import showInference
```

```
showInference(bn)
```



Попробуем поиспользовать нашу сеть и посмтреть вероятности для разных входных данных. Нарисуем сложную визуализацию ;(

```
import numpy as np

tests = [
    {"name": "Тест 1 – супер-прилежный", "evidence": {"studytime": "4", "failures": "0"},
    {"name": "Тест 2 – проблемный", "evidence": {"studytime": "1", "failures": "3"},
    {"name": "Тест 3 – середнячок", "evidence": {"studytime": "2", "failures": "1"},
    {"name": "Тест 4 – усердный+вечеринки", "evidence": {"studytime": "3", "failures": "0"}
]

def numeric_labels_for_var(bn, varname: str):
    """Получить числовые x-метки для переменной (если метки не числа – используем индексы)"""
    var = bn.variable(varname)
    labels = [str(l) for l in var.labels()]
```

```

xs = []
is_numeric = True
for s in labels:
    try:
        xs.append(float(s))
    except ValueError:
        is_numeric = False
        break
if not is_numeric:
    xs = list(range(len(labels)))
return np.array(xs, dtype=float), labels

def gaussian_smooth(y, sigma_points=3.0, window=41):
    """Простое гауссово сглаживание без SciPy."""
    win = int(window)
    if win % 2 == 0:
        win += 1
    half = win // 2
    grid = np.arange(-half, half+1, dtype=float)
    kernel = np.exp(-0.5 * (grid / float(sigma_points))**2)
    kernel /= kernel.sum()
    return np.convolve(y, kernel, mode="same")

def posterior_curve_smooth(bn, varname: str, evidence: dict, n_points=400):
    """Считает posterior(varname|evidence), интерполирует и сглаживает кривую."""
    ie = LazyPropagation(bn)
    ev = {k: str(v) for k, v in evidence.items()}
    ie.setEvidence(ev)
    ie.makeInference()
    pot = ie.posterior(varname)
    print("Evidence:", ev)
    print("Posterior P(G3):")
    print(pot)

    x_discrete, _ = numeric_labels_for_var(bn, varname)
    y_discrete = np.array(pot.toarray()).reshape(-1).astype(float)
    s = y_discrete.sum()
    if s > 0:
        y_discrete = y_discrete / s

    if x_discrete.size == 1:
        x_smooth = np.linspace(x_discrete[0]-0.5, x_discrete[0]+0.5, n_points)
        y_linear = np.full_like(x_smooth, y_discrete[0], dtype=float)
    else:
        x_smooth = np.linspace(float(x_discrete.min()), float(x_discrete.max()), n_points)
        y_linear = np.interp(x_smooth, x_discrete, y_discrete)

    y_smooth = gaussian_smooth(y_linear, sigma_points=3.0, window=51)
    y_smooth = np.clip(y_smooth, 0, None)
    area = np.trapezoid(y_smooth, x_smooth)
    if area > 0:
        y_smooth = y_smooth / area

    return x_discrete, y_discrete, x_smooth, y_smooth

```

```


target = "G3"
for t in tests:
    xd, yd, xs, ys = posterior_curve_smooth(bn, target, t["evidence"])
    showInference(bn, evs=t["evidence"])

    plt.figure(figsize=(13, 6))
    plt.plot(xs, ys)
    plt.scatter(xd, yd, s=20, alpha=0.6)

    plt.title(f'{t["name"]}\nEvidence: {t["evidence"]}')
    plt.xlabel("Оценка G3")
    plt.ylabel("Вероятность")
    plt.grid(True, alpha=0.3)
    plt.tight_layout()
    plt.show()


```

Evidence: {'studytime': '4', 'failures': '0', 'Dalc': '1', 'higher': '1'}
 Posterior P(G3):






Inference in 3.76ms




Evidence: {'studytime': '1', 'failures': '3', 'Dalc': '5', 'higher': '0'}

Posterior P(G3):

G3									
0	1	2	3	4	5	6	7	8	
9	10	11	12	13	14	15	16	17	
18	19								
----- ----- ----- ----- ----- ----- ----- ----- ----- -----									
---- ----- ----- ----- ----- ----- ----- ----- -----									
----- ----- -----									
0.0476	0.0476	0.0476	0.0476	0.0476	0.0476	0.0952	0.0476	0.0476	0.04
76	0.0476	0.0476	0.0476	0.0476	0.0476	0.0476	0.0476	0.0476	
0.0476	0.0476	0.0476							




Inference in 3.79ms




Evidence: {'studytime': '2', 'failures': '1', 'Dalc': '2', 'higher': '1'}

Posterior P(G3):

G3									
0	1	2	3	4	5	6	7	8	
9	10	11	12	13	14	15	16	17	
18	19								
----- ----- ----- ----- ----- ----- ----- ----- ----- -----									
----- ----- ----- ----- ----- ----- ----- ----- -----									
----- ----- -----									
0.0400	0.0400	0.0400	0.0400	0.0400	0.0400	0.0400	0.0400	0.0400	0.08
00	0.0400	0.1200	0.0800	0.0800	0.0400	0.0400	0.0400	0.0400	
0.0400	0.0400	0.0400							




Inference in 3.94ms




Evidence: {'studytime': '3', 'failures': '0', 'Dalc': '4', 'higher': '0'}
Posterior P(G3):

G3									
0	1	2	3	4	5	6	7	8	
9	10	11	12	13	14	15	16	17	
18	19								
----- ----- ----- ----- ----- ----- ----- ----- ----- -----									
---- ----- ----- ----- ----- ----- ----- ----- ----- -----									
----- ----- -----									
0.0476	0.0476	0.0476	0.0476	0.0476	0.0476	0.0476	0.0476	0.0476	0.04
76	0.0476	0.0476	0.0952	0.0476	0.0476	0.0476	0.0476	0.0476	0.0476
0.0476	0.0476	0.0476							



Inference in 4.12ms



Видно, что модель более менее различает успеваемость студентов по их данным.

Выводы:

- Построенная байесовская сеть адекватно отражает причинно-статистические связи усилия → успеваемость. Тесты показывают логичное поведение апостериоров, а сглаживание устранило проблему нулевых вероятностей.

- Главное отличие заключается в том, что BN даёт обоснованную вероятностную картину и позволяет делать выводы при неполной информации, тогда как дерево и регрессия фокусируются на предсказании целевой переменной при полностью известных признаках. По интерпретируемости BN и дерево сопоставимы в маленьких задачах, но BN сохраняет смысл "причина → следствие" и позволяет заглянуть под капот, а регрессия – нет.